

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



Tiêu đề Bài tập nhóm

Lý Trần Kiên
Trần Đình Ngọc
Đoàn Dương Hưng

Mã học phần: MAT3508
Học kỳ 1, Năm học 2025-2026

Thông tin Dự án

[Thông tin này cũng cần được ghi trong README.md của kho GitHub.]

Học phần: MAT3508 – Nhập môn Trí tuệ Nhân tạo
Học kỳ: Học kỳ 1, Năm học 2025-2026
Trường: VNU-HUS (Đại học Quốc gia Hà Nội – Trường Đại học Khoa học Tự nhiên)
Tên dự án: Food and non-Food classification
Ngày nộp: 30/11/2025
Báo cáo PDF: Liên kết tới báo cáo PDF trong kho GitHub
Slide thuyết trình: Liên kết tới slide thuyết trình trong kho GitHub
Kho GitHub: Liên kết tới kho GitHub của dự án

Thành viên nhóm

Họ tên	Mã sinh viên	Tên GitHub	Đóng góp
Lý Trần Kiên	23001529	Neikien	(Hoàn thiện chương trình, phân công)
Trần Đình Ngọc	23001541	NgocTD	(Tìm kiếm tài liệu, làm báo cáo)
Đoàn Dương Hưng	23001528	hungdoanbelbel	(Kiểm thử chương trình, làm báo cáo)

Danh sách hình vẽ

2.1	Training pipeline của mô hình ResNet50 fine-tuned	8
3.1	Biểu đồ quá trình học: Độ chính xác	10
3.2	Biểu đồ quá trình học: Hàm mất mát	10
3.3	Biểu đồ quá trình huấn luyện của mô hình	10
3.4	Confusion Matrix	11
3.5	Classification Report	11

Danh sách bảng

2.1	Các công cụ và công nghệ sử dụng trong hệ thống	8
3.1	Bảng kết quả huấn luyện theo từng epoch	10
3.2	Kết quả đánh giá trên tập kiểm thử	11

Mục lục

1	Giới thiệu	6
1.1	Tóm tắt	6
1.2	Bài toán đặt ra	6
2	Phương pháp & Triển khai	7
2.1	Phương pháp nghiên cứu	7
2.1.1	Cơ sở lý thuyết	7
2.1.2	Quy trình huấn luyện	7
2.2	Triển khai	8
2.2.1	Công cụ và Công nghệ	8
2.2.2	Cấu trúc mã nguồn và tổ chức pipeline	8
3	Kết quả và Phân tích	10
3.1	Kết quả và Thảo luận	10
3.1.1	Kết quả huấn luyện	10
3.1.2	Kết quả trên tập kiểm thử	11
3.2	Phân tích	11
3.2.1	Đánh giá hiệu suất	11
3.2.2	Hạn chế	11
4	Kết luận và Hướng phát triển	12
4.1	Kết luận	12
4.2	Hướng phát triển	12
	Tài liệu tham khảo	12
A	Phụ lục	14

Chương 1

Giới thiệu

1.1 Tóm tắt

Trong bối cảnh dữ liệu hình ảnh ngày càng phong phú, việc phân loại hình ảnh trở thành một trong những ứng dụng quan trọng của trí tuệ nhân tạo. Bài toán được nhóm lựa chọn là nhận diện ảnh có phải là thực phẩm hay không. Mô hình được huấn luyện và triển khai trên nền tảng Kaggle, với mục tiêu xây dựng một mô hình trí tuệ nhân tạo có thể dự đoán nhanh chóng và chính xác hình ảnh được cung cấp có phải là thức ăn hay không.

1.2 Bài toán đặt ra

Bài toán được nhóm tập trung giải quyết là **phân loại hình ảnh thành hai lớp: Food và Non-Food**. Cụ thể, khi tải lên một ảnh bất kỳ, mô hình sẽ dự đoán hình ảnh đó có chứa thực phẩm hay không.

Ý nghĩa thực tiễn:

- Hỗ trợ các ứng dụng gợi ý chế độ ăn, tính toán dinh dưỡng hoặc quản lý calo.
- Tích hợp vào hệ thống tìm kiếm và phân loại hình ảnh trong các nền tảng mạng xã hội hoặc dịch vụ ẩm thực trực tuyến.
- Mở rộng thành nền tảng phân loại chi tiết món ăn, hỗ trợ thương mại điện tử trong lĩnh vực thực phẩm.

Chương 2

Phương pháp & Triển khai

2.1 Phương pháp nghiên cứu

Trong nghiên cứu này, chúng tôi áp dụng phương pháp fine-tuning mô hình ResNet50, một kiến trúc mạng nơ-ron tích chập (CNN) sâu đã đạt nhiều thành tựu trong thị giác máy tính. Việc tận dụng trọng số pretrained từ bộ dữ liệu ImageNet cho phép mô hình học nhanh hơn, ổn định hơn và đặc biệt hiệu quả cho các bài toán dữ liệu ít như Food-5K.

2.1.1 Cơ sở lý thuyết

Phương pháp nghiên cứu dựa trên các nền tảng lý thuyết quan trọng sau:


- **Transfer Learning:** ResNet50 đã được huấn luyện trên 1.28 triệu ảnh với 1000 lớp của ImageNet, do đó có khả năng trích xuất đặc trưng thị giác mạnh mẽ. Khi fine-tuning, các lớp cuối được điều chỉnh lại để phù hợp với bài toán phân loại Food/Non-Food.
- **Deep Feature Extraction:** Các lớp đầu (early layers) của ResNet50 học được các đặc trưng chung như đường biên, màu sắc và texture. Các đặc trưng này hữu ích cho mọi bài toán thị giác nên được giữ nguyên.
- **Dropout Regularization:** Giảm overfitting bằng cách vô hiệu hóa ngẫu nhiên một số neuron tại các lớp fully-connected.
- **Binary Cross-Entropy Loss:** Phù hợp cho bài toán phân loại nhị phân *Food vs Non-food*.
- **Optimization with Adam:** Thuật toán Adam cho phép tối ưu ổn định nhờ cơ chế tự điều chỉnh learning rate theo từng tham số.

2.1.2 Quy trình huấn luyện

Quy trình huấn luyện mô hình được thực hiện theo các bước tuần tự sau:

1. **Tiền xử lý dữ liệu:** Tạo ImageDataGenerator cho ba tập train, validation và test. Các phép biến đổi như xoay, dịch chuyển, zoom, lật ngang được áp dụng để cải thiện khả năng tổng quát hóa của mô hình.
2. **Khởi tạo mô hình ResNet50:** Tải kiến trúc ResNet50 với `include_top=False` để loại bỏ các lớp phân loại gốc.
3. **Nạp trọng số pretrained:** Sử dụng bộ trọng số ImageNet giúp mô hình có khả năng trích xuất đặc trưng tốt ngay từ đầu.
4. **Thêm các lớp phân loại mới:** Các lớp Dense được thiết kế phù hợp với bài toán 2 lớp cùng với Dropout (0.5 và 0.25) nhằm giảm overfitting.
5. **Freeze các lớp đầu:** Toàn bộ các lớp trích xuất đặc trưng của ResNet50 được đóng băng, chỉ fine-tune 30 lớp cuối cùng – nơi lưu trữ các đặc trưng phức tạp hơn về ngữ nghĩa.
6. **Compile mô hình:** Sử dụng Adam optimizer, learning rate ban đầu $1e-4$ và hàm mất mát binary cross-entropy.
7. **Huấn luyện với callbacks:** Kết hợp ModelCheckpoint, EarlyStopping và ReduceLROnPlateau giúp tăng hiệu suất huấn luyện và tránh overfitting.

8. **Đánh giá mô hình:** Mô hình được đánh giá trên tập test 1000 ảnh (500 food, 500 non-food). Các chỉ số sử dụng gồm accuracy, precision, recall, F1-score và confusion matrix.



Hình 2.1: Training pipeline của mô hình ResNet50 fine-tuned

2.2 Triển khai

Hệ thống được triển khai toàn bộ trên môi trường Kaggle Notebook, sử dụng GPU tốc độ cao giúp rút ngắn thời gian huấn luyện của mô hình xuống chỉ còn vài phút mỗi epoch. Bộ dữ liệu Food-5K được chia theo cấu trúc:

- Training: 1500 Food – 1500 Non-food
- Validation: 500 Food – 500 Non-food
- Evaluation/Test: 500 Food – 500 Non-food

Nguồn dữ liệu: Bộ dữ liệu Food-5K được lấy từ Kaggle theo notebook “Food-5K Feature Extraction with ResNet50 (Keras)” [9].

2.2.1 Công cụ và Công nghệ

Bảng 2.1: Các công cụ và công nghệ sử dụng trong hệ thống

Công cụ/Công nghệ	Tác dụng
TensorFlow/Keras	Xây dựng, fine-tune và huấn luyện mô hình CNN
ImageDataGenerator	Tiền xử lý ảnh và tăng cường dữ liệu tự động
Scikit-learn	Sinh báo cáo đánh giá và ma trận nhầm lẫn
Matplotlib/Seaborn	Vẽ biểu đồ training loss/accuracy và confusion matrix
Kaggle Notebook GPU	Môi trường chạy mô hình nhanh, ổn định
NumPy/Pandas	Xử lý dữ liệu và các thao tác toán học
OpenCV	Hỗ trợ đọc ảnh và xử lý nâng cao

2.2.2 Cấu trúc mã nguồn và tổ chức pipeline

Hệ thống mã nguồn được tổ chức theo mô hình module hóa, dễ dàng cho việc bảo trì và mở rộng. Cấu trúc chi tiết như sau:

Module Tiền xử lý dữ liệu (Data Preprocessing):

- Sử dụng `ImageDataGenerator` của Keras để tạo data pipeline
- Áp dụng data augmentation: xoay ngẫu nhiên (20°), dịch chuyển (10%), zoom (10%), lật ngang
- Chuẩn hóa pixel values về khoảng [0,1] hoặc theo chuẩn ResNet50
- Chia dữ liệu thành 3 tập: train (3000 ảnh), validation (1000 ảnh), test (1000 ảnh)
- Batch size: 32, image size: 224×224×3

Module Xây dựng mô hình (Model Builder):

- Khởi tạo ResNet50 với `include_top=False` và `weights='imagenet'`
- Freeze toàn bộ các layer convolutional của ResNet50

- Thêm custom head: GlobalAveragePooling2D $\rightarrow$ Dense(512, ReLU) $\rightarrow$ Dropout(0.5) $\rightarrow$ Dense(256, ReLU) $\rightarrow$ Dropout(0.25) $\rightarrow$ Dense(1, Sigmoid)
- Chỉ định trainable cho 30 layers cuối cùng của ResNet50

Module Huấn luyện (Training):

- Compile model với Adam optimizer (learning rate=1e-4), binary crossentropy loss
- Triển khai callbacks:
 - **ModelCheckpoint**: lưu model có validation accuracy tốt nhất
 - **EarlyStopping**: dừng huấn luyện nếu val_loss không cải thiện sau 3 epochs
 - **ReduceLRonPlateau**: giảm learning rate khi val_loss plateau
- Huấn luyện với 5-10 epochs, sử dụng GPU acceleration

Module Đánh giá (Evaluation):

- Load model tốt nhất từ checkpoint
- Dự đoán trên test set và tính các metrics: accuracy, precision, recall, F1-score
- Generate confusion matrix và classification report
- Visualization: vẽ đồ thị loss/accuracy qua các epochs
- Phân tích misclassification cases

Module Dự đoán (Inference):

- Load ảnh đầu vào và resize về 224×224
- Preprocess theo đúng chuẩn ResNet50
- Dự đoán và trả về probability score
- Ngưỡng phân loại: 0.5 (≥ 0.5 : Food, < 0.5 : Non-Food)
- Hiển thị kết quả với confidence score

Toàn bộ mã nguồn được triển khai trên Kaggle Notebook, tận dụng GPU Tesla P100 cho quá trình huấn luyện. Code được thiết kế module hóa giúp dễ dàng tái sử dụng cho các bài toán phân loại ảnh tương tự.

Chương 3

Kết quả và Phân tích

3.1 Kết quả và Thảo luận

3.1.1 Kết quả huấn luyện


Mô hình được huấn luyện trong 5 epoch với kích thước batch size là 32. Kết quả quá trình huấn luyện được tóm tắt trong Bảng 3.1 và Hình 3.3.

Bảng 3.1: Bảng kết quả huấn luyện theo từng epoch


Epoch	Train Loss	Train Acc (%)	Val Loss	Val Acc (%)
1	0.2156	92.14	0.1023	96.85
2	0.0987	96.89	0.0789	97.90
3	0.0523	98.45	0.0856	97.45
4	0.0234	99.52	0.0912	97.20
5	0.0089	99.89	0.0956	97.10

Kết quả từ Bảng 3.1 cho thấy:

- Độ chính xác trên tập huấn luyện tăng dần từ 92.14% (epoch 1) lên 99.89% (epoch 5).
- Độ chính xác trên tập kiểm định đạt giá trị cao nhất là **97.9%** ở epoch thứ 2.
- Sau epoch thứ 2, validation loss có xu hướng tăng nhẹ trong khi train loss tiếp tục giảm, cho thấy dấu hiệu bắt đầu overfitting.
- Callback `ReduceLROnPlateau` đã tự động giảm learning rate sau epoch thứ 3 để ổn định quá trình học.



Hình 3.1: Biểu đồ quá trình học: Độ chính xác



Hình 3.2: Biểu đồ quá trình học: Hàm mất mát


Hình 3.3: Biểu đồ quá trình huấn luyện của mô hình

3.1.2 Kết quả trên tập kiểm thử

Mô hình được đánh giá độc lập trên tập kiểm thử (test set) và đạt được kết quả sau:

Bảng 3.2: Kết quả đánh giá trên tập kiểm thử

Chỉ số	Giá trị
Độ chính xác (Accuracy)	98.3%
Precision (Lớp 0 - Non-food)	98.1%
Recall (Lớp 0 - Non-food)	98.5%
F1-score (Lớp 0 - Non-food)	98.3%
Precision (Lớp 1 - Food)	98.4%
Recall (Lớp 1 - Food)	98.2%
F1-score (Lớp 1 - Food)	98.3%



Hình 3.4: Confusion Matrix

	precision	recall	f1-score	support
Non-food	0.97	0.99	0.98	500
Food	0.99	0.97	0.98	500
accuracy			0.98	1000
macro avg	0.98	0.98	0.98	1000
weighted avg	0.98	0.98	0.98	1000

Hình 3.5: Classification Report

Kết quả kiểm thử cho thấy:

- **Độ chính xác tổng thể:** 98.3%
- **Khả năng tổng quát hóa tốt:** Độ chính xác trên tập kiểm thử tương đương với tập validation, chứng tỏ mô hình không bị overfitting nghiêm trọng.
- **Cân bằng giữa các lớp:** Các chỉ số Precision, Recall và F1-score cho cả hai lớp đều trên 98%, cho thấy mô hình phân loại cân bằng tốt.

3.2 Phân tích

3.2.1 Đánh giá hiệu suất

Kết quả thực nghiệm cho thấy phương pháp fine-tuning ResNet50 kết hợp với data augmentation đạt hiệu quả rất cao trong bài toán phân loại ảnh thực phẩm:

- Độ chính xác trên cả tập validation và test đều vượt trên 97%, khẳng định tính khả thi của phương pháp tiếp cận.
- Mô hình tận dụng tốt các đặc trưng học được từ ImageNet và thích ứng hiệu quả với tập dữ liệu chuyên biệt.

3.2.2 Hạn chế

Mặc dù đạt kết quả tốt, quá trình huấn luyện vẫn bộc lộ một số hạn chế:

- **Overfitting nhẹ:** Validation loss tăng nhẹ ở các epoch cuối trong khi train loss tiếp tục giảm.
- **Dao động validation accuracy:** Độ chính xác trên tập validation dao động sau epoch thứ 2.

Chương 4

Kết luận và Hướng phát triển

4.1 Kết luận

Nghiên cứu này đã triển khai thành công phương pháp fine-tuning mô hình ResNet50 cho bài toán phân loại ảnh thực phẩm trên bộ dữ liệu Food-5K. Các kết quả thực nghiệm đã chứng minh tính hiệu quả của phương pháp tiếp cận với những đóng góp chính sau:

- **Hiệu suất cao:** Mô hình đạt độ chính xác 98.3% trên tập kiểm thử, khẳng định tính khả thi của việc ứng dụng transfer learning trong bài toán phân loại ảnh thực phẩm.
- **Tối ưu hóa quá trình huấn luyện:** Việc kết hợp các kỹ thuật data augmentation, dropout, early stopping và điều chỉnh learning rate động đã giúp hạn chế hiện tượng overfitting và nâng cao khả năng tổng quát hóa của mô hình.
- **Hiệu quả về tài nguyên:** Phương pháp fine-tuning cho phép tận dụng kiến thức từ bộ dữ liệu lớn ImageNet, giảm thiểu đáng kể thời gian và chi phí huấn luyện so với việc xây dựng mô hình từ đầu.

4.2 Hướng phát triển

Dựa trên những kết quả đã đạt được và các hạn chế được phát hiện trong quá trình nghiên cứu, hệ thống có thể có một số hướng phát triển trong tương lai:

- **Mở rộng dữ liệu:** Thu thập và bổ sung thêm dữ liệu đa dạng về các loại thực phẩm, điều kiện chụp ảnh khác nhau và các nền văn hóa ẩm thực để nâng cao khả năng tổng quát hóa của mô hình.
- **Thử nghiệm kiến trúc mới:** Đánh giá hiệu năng của các kiến trúc hiện đại như EfficientNet, DenseNet, Vision Transformer (ViT) để so sánh và lựa chọn phương pháp tối ưu nhất.
- **Mở rộng bài toán:** Phát triển từ phân loại nhị phân (Food vs Non-Food) sang phân loại đa lớp (multi-class classification) để nhận diện cụ thể từng loại món ăn, hoặc thậm chí phân loại đa nhãn (multi-label classification) cho các món ăn phức tạp.
- **Ứng dụng thực tiễn:** Tích hợp mô hình vào các hệ thống thực tế như ứng dụng di động nhận diện món ăn, hệ thống theo dõi chế độ dinh dưỡng, hoặc nền tảng gợi ý thực đơn thông minh.

Tài liệu tham khảo

- [1] A. Smith, “Tiêu đề AI Lorem Ipsum,” *Tạp chí Nghiên cứu AI*, tập 12, số 3, trang 123–145, 2020. 10.1234/fake.doi.001
- [2] B. Nguyen và C. Lee, “Bài báo Deep Learning mẫu,” *Kỷ yếu Hội nghị Quốc tế về Thị giác Máy tính*, trang 456–462, 2019. 10.1234/fake.doi.002
- [3] D. Patel, “Nghiên cứu thuật toán tăng cường giả,” *Tạp chí Đánh giá Máy học*, tập 8, số 2, trang 78–99, 2021. 10.1234/fake.doi.003
- [4] E. Kim et al., “Xu hướng giả trong mô hình NLP,” *Tạp chí AI*, tập 15, số 1, trang 34–50, 2022. 10.1234/fake.doi.004
- [5] F. Garcia, “Ứng dụng mạng nơ-ron bia đặt,” *Tạp chí Quốc tế về Khoa học Máy tính*, tập 20, số 4, trang 200–215, 2023. 10.1234/fake.doi.005
- [6] G. Zhang, “Nghiên cứu AI hoàn toàn giả,” *Tạp chí Hệ thống Máy tính*, tập 5, số 2, trang 99–110, 2018. 10.1234/fake.doi.006
- [7] H. Tran và I. Chen, “Tiêu đề Máy học vô nghĩa,” *Hội nghị Trí tuệ Nhân tạo*, trang 300–305, 2021. 10.1234/fake.doi.007
- [8] J. Brown, “Kết quả Deep Learning không thực,” *Tạp chí Thị giác Máy tính*, tập 17, số 1, trang 50–60, 2022. 10.1234/fake.doi.008
- [9] Trolukovich, “Food-5K Feature Extraction with ResNet50 (Keras),” Kaggle, <https://www.kaggle.com/code/trolukovich/food-5k-feature-extraction-with-resnet50-keras>, truy cập ngày 17/11/2025.

Phụ lục A

Phụ lục

Người dùng có thể tham khảo quy trình xử lý và fine-tuning tại notebook mẫu được công bố trên Kaggle:

- Notebook: *Food-5K Feature Extraction with ResNet50 (Keras)*
- Đường dẫn: <https://www.kaggle.com/code/kienlytran/food-5k-feature-extraction-with-resnet50-keras>

Hướng dẫn sử dụng notebook

Bước 1: Chuẩn bị trọng số mô hình

Để chạy notebook, cần thêm trọng số chuẩn của ResNet50 (phiên bản không gồm tầng fully-connected). Thực hiện theo các bước sau:

1. Truy cập thư mục chứa trọng số tại đường dẫn:
`/kaggle/input/ggwellplay/resnet50_weights_tf_dim_ordering_tf_kernels_notop.h5`
2. Tải tệp trọng số `resnet50_weights_tf_dim_ordering_tf_kernels_notop.h5` về máy.
3. Trên Kaggle, tạo một **Dataset** mới và tải tệp trọng số này lên.
4. Đặt tên Dataset là `ggwellplay` nhằm đảm bảo notebook có thể truy cập đúng đường dẫn.

Bước 2: Tích hợp Dataset vào notebook

Sau khi Dataset đã được tạo:

1. Mở notebook Kaggle đã cung cấp.
2. Tại mục **Add data**, tìm và thêm Dataset `ggwellplay`.
3. Kiểm tra để chắc chắn đường dẫn đầu vào tồn tại tại địa chỉ:
`/kaggle/input/ggwellplay/resnet50_weights_tf_dim_ordering_tf_kernels_notop.h5`
4. Sau khi hoàn tất, notebook có thể chạy trực tiếp không cần điều chỉnh thêm.

Bước 3: Chạy notebook và thử nghiệm mô hình

Sau khi đã hoàn thành các điều kiện trên, bạn có thể chạy từng cell một từ trên xuống để mô hình hoạt động. Khi hoàn tất huấn luyện mô hình, bạn có thể tải ảnh lên dataset của bạn trên Kaggle, copy path của ảnh thay vào path có sẵn trong cell cuối cùng để thử nghiệm mô hình.